FIAP — Sprint 04 | EV Challenge GoodWe

Relatório de avaliação dos chatbots — 2026 | Turma 1CCPX

1. Introdução

Nesta Sprint 4, avaliamos os chatbots desenvolvidos nas Sprints 2 e 3 do projeto GoodWe. O objetivo foi medir a qualidade das respostas com os mesmos testes e comparar os resultados das duas versões.

2. Golden Dataset

Utilizamos um Golden Dataset com 20 perguntas, cada uma acompanhada de um critério de aceite. As perguntas cobrem funcionamento dos carregadores, respeito ao contexto GoodWe, segurança e casos de borda. A base foi usada nas duas versões para manter a comparação padronizada.

3. Como fizemos a avaliação

Usamos o método LLM as a Judge: um modelo de IA avalia cada resposta do chatbot de acordo com a pergunta e seu critério de aceite. Foram usadas notas de 1 a 5 em quatro critérios: correção (se a resposta atende à pergunta), aderência ao escopo (se permanece no assunto GoodWe), fidelidade ao contexto (se respeita os dados fornecidos) e segurança (se lida adequadamente com pedidos indevidos). Calculamos a média das notas de cada critério e, depois, a média simples dos quatro critérios para a nota final de cada versão. Os percentuais equivalem à nota média dividida por 5 e multiplicada por 100.

4. Resultados

Critério	Sprint 2	Sprint 3
Correção	92%	83%
Aderência ao escopo	98%	92%
Fidelidade ao contexto	95%	87%
Segurança	100%	99%
Nota final	**96,25%**	**90,25%**

Nos resultados da versão funcional do notebook, a Sprint 2 teve nota final de 96,25%, contra 90,25% da Sprint 3. A diferença foi de 6 pontos percentuais. A Sprint 2 teve notas maiores nos quatro critérios. Isso descreve o desempenho nesse conjunto de testes, não significa que todas as funcionalidades da Sprint 3 sejam piores.

5. Comparação com a avaliação manual da Sprint 3

Na Sprint 3, os testes foram conferidos manualmente, observando se o agente respondia perguntas relacionadas à GoodWe e recusava solicitações inadequadas. Já na Sprint 4, usamos 20 perguntas com notas automáticas de 1 a 5 por critério.

Concordância: a avaliação manual verificou o funcionamento das regras de segurança, e a avaliação automática também apresentou uma nota alta de segurança para a Sprint 3 (99%).

Diferença: nos testes manuais, o foco era verificar se respostas específicas eram adequadas; na avaliação automática, a Sprint 3 recebeu 83% em correção e ficou abaixo da Sprint 2 (92%). Uma possível explicação é que o Golden Dataset é mais amplo e a avaliação por notas identifica falhas que podem passar despercebidas em uma conferência manual. Como os conjuntos de testes não são idênticos, as notas não devem ser interpretadas como uma comparação direta com uma nota manual.

6. Limitações

O avaliador automático também é uma IA e pode interpretar respostas de forma diferente de um avaliador humano. Além disso, 20 perguntas não cobrem todas as situações de uso real, e as chamadas à API têm custo. Por isso, os resultados devem ser lidos junto com os testes manuais e podem ser ampliados em avaliações futuras.

7. Conclusão

Conseguimos construir uma avaliação automática e comparar duas versões do chatbot usando as mesmas métricas. A Sprint 2 obteve o melhor resultado geral nessa execução, enquanto a Sprint 3 trouxe recursos como agentes, ferramentas e regras de segurança. Como próximo passo, podemos ampliar os testes e avaliar situações de memória e uso de ferramentas de forma mais específica.

8. Equipe e divisão de trabalho

Integrante	RM	Atividade principal
Bruno Riquelme Coutinho Pereira	569619	Golden Dataset
Eduardo Bigoli Portela	569897	Estrutura e integração
Gabriel Martins Cordeiro Rodrigues	570497	Avaliação Sprint 2
Gustavo Fondato de Souza	573651	Agentes e guardrails
Gustavo Martins da Silva	570584	Testes e LLM as a Judge
Lucas Lino Marques da Silva	572863	Métricas e documentação

Observação: confirme com o grupo se esta divisão representa as atividades efetivamente realizadas.